



Création et utilisation de la base de données

HYANI Hishem



Laplace Immo

Contexte du projet DATAImmo

L'agence souhaite utiliser des données pour identifier les régions où le marché est le plus porteur.

- Créer un BDD
- Réaliser un POC (1er semestre 2020)



La stratégie de sauvegarde

- Sauvegarde en local pour le POC
- Evolution possible vers un stockage en cloud après validation du POC

Conformité RGPD

- Ne pas faire apparaître le nom ni l'adresse
- Afin de garantir l'unicité du bien et de la transaction besoin de l'adresse.

Les données initiales

“Les documents sont validés, un très bon travail a été réalisé.” (CR réunion)

Documents fournis :

- **Référentiel géographique** : lien entre les régions et communes (complet)
- **Données communes**: population dans les communes (incomplet)
- **Valeurs foncières** : information sur les biens et les transactions (à nettoyer)

Traitement des données

Valeurs foncières : informations sur les biens et les transactions (à nettoyer)

- Surface Carrez >> Surface du bâti
- Nombre de pièces nul
- Incohérence : même adresse pour une maison et un appartement
- Adresse incomplète
- Outliers : plusieurs millions pour moins de 5 m²
- Doublons : même transaction
- Anonymisation des adresses avec ID unique

Extrait du dictionnaire des données


DICTIONNAIRE DES DONNÉES - Valeurs foncières

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
id_bien	Id unique pour le bien	Integer	NC	Elémentaire	Ne doit pas être nul	
no_voie	Numéro des rues	Integer	NC	Elémentaire	RGPD => à supprimer après traitement	
type_de_voie	Plusieurs valeurs (rue, avenue, chemin, etc.)	Varchar	4	Elémentaire	RGPD => à supprimer après traitement	
nom_voie	Nom de la rue	Varchar	50	Elémentaire	RGPD => à supprimer après traitement	
surface	Surface réel du bati	float		Elementaire		
nbre_piece	Nombre de pièces	Integer		Elementaire		

DICTIONNAIRE DES DONNÉES - Référentiel géographique

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
id_com_insee	Code commune insee (Code departement- Code commune)	Varchar	6	Concaté	non nul	
nom_com	Le nom de la commune	Varchar		Elementaire		
id_region	Code région insee	Integer		Elementaire	non nul	
nom_region	Nom de la région	Varchar		Elementaire		

Le schéma relationnel normalisé (SQL Power architect)



La base de données avec les tables créées et les données chargées

- SQL Power Architect fournit le script pour générer les tables PostgreSQL
- J'ai nettoyé les fichiers avec python et modifier les données pour les faire correspondre au schéma relationnel. On obtient ainsi 5 fichiers.
- Charger les données dans la BDD. Par exemple pour la table region, je charge les données du fichier Region.csv :

```
COPY region(id_region, nom_region)  
FROM 'Last/Region.csv'  
DELIMITER ','  
CSV HEADER;
```


PostgreSQL@postgres-db public@projet03

sql-1 (PostgreSQL@postgres-... commune

Propriétés Données

Entrez une expression SQL pour filtrer les résultats, par exemple column_name=10

	A-Z id_com_insee	123 id_region	A-Z nom_com	123 pop_tot
1	01001	84	L'Abergement-Clémenciat	798
2	01002	84	L'Abergement-de-Varey	257
3	01003	84	Amareins	[NULL]
4	01004	84	Ambérieu-en-Bugey	14514
5	01005	84	Ambérieux-en-Dombes	1776
6	01006	84	Ambléon	118
7	01007	84	Ambronay	2915
8	01008	84	Ambrutrix	777
9	01009	84	Andert-et-Condon	335
10	01010	84	Anglefort	1122
11	01011	84	Apremont	379
12	01012	84	Aranc	333
13	01013	84	Arandas	147
14	01014	84	Arbent	3442
15	01015	84	Arboys en Bugey	667
16	01016	84	Arbigny	469




Requêtes SQL et résultats

Requête 1

1. Nombre total d'appartements vendus au 1er semestre 2020.

```
SELECT COUNT(b.id_bien) AS nbre_app_vendu  
FROM bien b  
JOIN vente v on v.id_bien=b.id_bien  
WHERE b.id_type_bien=2;
```



	123 nbre_app_vendu
1	30443

Requête 2

2. Le nombre de ventes d'appartement par région pour le 1er semestre 2020.

```
SELECT r.id_region, r.nom_region, COUNT(b.id_bien) AS nbre_app_vendu  
FROM bien b  
JOIN vente v on v.id_bien=b.id_bien  
JOIN commune c on c.id_com_insee=b.id_com_insee  
RIGHT JOIN region r on c.id_region=r.id_region  
GROUP BY r.id_region  
ORDER BY r.id_region;
```

	123 id_region	A-Z nom_region	123 nbre_app_vendu
1	0	Collectivités d'outre-mer	0
2	1	Guadeloupe	2
3	2	Martinique	78

Requête 3

3. Proportion des ventes d'appartements par le nombre de pièces.

```
SELECT b.nbre_piece,  
COUNT(b.id_bien)*100.0/(SELECT COUNT(id_vente)FROM vente ) AS Pourcentage  
FROM bien b  
RIGHT JOIN vente v ON v.id_bien=b.id_bien  
GROUP BY b.nbre_piece  
ORDER BY b.nbre_piece;
```

	123 nbre_piece	123 pourcentage
1	1	19.789996066208733
2	2	29.4731745695524556
3	3	28.1598934850364632
4	4	16.1588041274548371
5	5	4.9232910702938239

Requête 4

4. Liste des 10 départements où le prix du mètre carré est le plus élevé.

```
CREATE TEMP TABLE tmp_04(id_vente INTEGER, prix_vente INTEGER, departement VARCHAR, surface FLOAT );
```

```
INSERT INTO tmp_04(id_vente, prix_vente, departement , surface )  
SELECT v.id_vente,  
v.prix_vente,  
LEFT(b.id_com_insee, LENGTH(b.id_com_insee) -3) AS Dep,  
b.surface  
FROM bien b  
RIGHT JOIN vente v ON v.id_bien=b.id_bien;
```

```
SELECT departement,  
AVG(prix_vente*1.0/surface) AS Prix_metre_carre_moyen  
FROM tmp_04  
GROUP BY departement  
ORDER BY Prix_metre_carre_moyen DESC  
LIMIT 10;
```

	AZ departement	123 prix_metre_carre_moyen
1	75	12025.713833877195
2	92	7419.323015495396
3	94	5327.854671968261
4	06	4748.173174837411
5	93	4371.765903036442

Requête 5

5. Prix moyen du mètre carré d'une maison en Île-de-France.

```
CREATE TEMP TABLE tmp_05(prix_vent INTEGER, surface FLOAT);
```

```
INSERT INTO tmp_05(prix_vent, surface)
SELECT v.prix_vente ,b.surface
FROM bien b
JOIN commune c ON c.id_com_insee=b.id_com_insee
JOIN region r ON r.id_region=c.id_region
JOIN vente v ON v.id_bien=b.id_bien
WHERE r.id_region=11;
```

```
SELECT AVG(prix_vent/surface) AS prix_moyen_metre_carrée_idf
FROM tmp_05;
```

	123 prix_moyen_metre_carrée_idf
1	7030.295503066304

Requête 6

6. Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés.

```
SELECT b.id_bien, r.nom_region, c.nom_com, v.prix_vente, b.surface
```

```
FROM Bien b
```

```
JOIN vente v ON v.id_bien=b.id_bien
```

```
JOIN commune c ON c.id_com_insee=b.id_com_insee
```

```
JOIN region r ON r.id_region=c.id_region
```

```
JOIN type_bien t ON t.id_type_bien=b.id_type_bien
```

```
WHERE t.id_type_bien=2
```

```
ORDER BY v.prix_vente DESC
```

```
LIMIT 10;
```

123 id_bien	A-Z nom_region	A-Z nom_com	123 prix_vente	123 surface
29035	Ile-de-France	Paris 16e	9000000	10.0
5047	Ile-de-France	Corbeil-Essonnes	8600000	62.0
3481	Ile-de-France	Paris 7e	8577713	289.0
7277	Ile-de-France	Paris 17e	7620000	42.0
9566	Ile-de-France	Paris 6e	7600000	200.0
16995	Ile-de-France	Paris 1er	7535000	143.0
402	Ile-de-France	Paris 16e	7420000	357.0
15630	Ile-de-France	Paris 16e	7200000	241.0
1856	Ile-de-France	Paris 1er	7050000	310.0
18250	Ile-de-France	Paris 1er	6600000	76.0


Requête 7

7. Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020.

SELECT

(COUNT(CASE WHEN v.date_vente >= '2020/04/01' THEN 1 END)- COUNT(CASE WHEN v.date_vente < '2020/04/01' THEN 1 END))*100.0/COUNT(CASE WHEN v.date_vente < '2020/04/01' THEN 1 END)

AS taux_evolution
FROM vente v;



123 taux_evolution	
1	3.7674189172524356

Requête 8

8. Le classement des régions par rapport au prix au mètre carré des appartement de plus de 4 pièces.

```
CREATE TEMP TABLE tmp_08 (nom_region VARCHAR, prix INTEGER, surface FLOAT);
INSERT INTO tmp_08(nom_region,prix,surface)
SELECT r.nom_region, v.prix_vente , b.surface
FROM bien b
RIGHT JOIN vente v ON v.id_bien=b.id_bien
JOIN type_bien t ON t.id_type_bien=b.id_type_bien
JOIN commune c ON c.id_com_insee=b.id_com_insee
JOIN region r ON c.id_region=r.id_region
WHERE t.id_type_bien =2
AND b.nbre_piece > 4;
```

```
SELECT nom_region, AVG(prix/surface) AS prix_moy_app_sup_4piece
FROM tmp_08
GROUP BY nom_region
ORDER BY prix_moy_app_sup_4piece DESC;
```

	AZ nom_region	123 prix_moy_app_sup_4piece
1	Ile-de-France	8074.28030778794
2	La Réunion	3659.826139088729
3	Corse	3481.1658413365344
4	Provence-Alpes-Côte d'Azur	3040.056857046688
5	Auvergne-Rhône-Alpes	2781.1906734628815
6	Nouvelle-Aquitaine	2541.6121418997427
7	Bretagne	2271.8619798682876
8	Hauts-de-France	2203.606505856694

Requête 9

9. Liste des communes ayant eu au moins 50 ventes au 1er trimestre

```
SELECT c.nom_com, COUNT(v.id_vente) AS nmbr_vente
FROM bien b
JOIN commune c ON c.id_com_insee=b.id_com_insee
RIGHT JOIN vente v on v.id_bien=b.id_bien
WHERE v.date_vente < '2020/04/01'
GROUP BY c.nom_com
HAVING COUNT(v.id_vente)>=50
ORDER BY nmbr_vente ASC;
```

	A-Z nom_com	123 nmbr_vente
1	Ajaccio	50
2	Issy-les-Moulineaux	50
3	Versailles	53
4	Puteaux	53
5	Saint-Maur-des-Fossés	56
6	Sète	58
7	Toulon	59
8	Levallois-Perret	59
9	Paris 4e	59
10	Marseille 9e	61
11	Rennes	61

Requête 10

10. Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces.

```
CREATE TEMP TABLE tmp_10(nbre_piece INTEGER ,prix_vente INTEGER, surface FLOAT);
```

```
INSERT INTO tmp_10(nbre_piece, prix_vente, surface)
```

```
SELECT b.nbre_piece, v.prix_vente, b.surface
```

```
FROM bien b
```

```
JOIN type_bien t ON t.id_type_bien=b.id_type_bien
```

```
RIGHT JOIN vente v ON v.id_bien=b.id_bien
```

```
WHERE t.id_type_bien=2
```

```
AND (b.nbre_piece=2 OR b.nbre_piece=3);
```

```
SELECT (Prix_moy_app_2_piece-Prix_moy_app_3_piece)*100.0/Prix_moy_app_3_piece AS
```

```
Pourcentage_2_par_rapport_3
```

```
FROM(SELECT
```

```
AVG(CASE WHEN nbre_piece=2 THEN prix_vente/surface END) AS Prix_moy_app_2_piece,
```

```
AVG(CASE WHEN nbre_piece=3 THEN prix_vente/surface END) AS Prix_moy_app_3_piece
```

```
FROM tmp_10);
```

	123 pourcentage_2_par_rapport_3
1	15.245132193985045

Requête 11

11. Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69.

```
CREATE TEMP TABLE tmp_11(cod_dep VARCHAR, nom_com VARCHAR, prix_vente INTEGER, surface FLOAT);
```

```
INSERT INTO tmp_11(cod_dep, nom_com, prix_vente, surface)
SELECT LEFT(c.id_com_insee, LENGTH(c.id_com_insee)-3) AS dep, c.nom_com, v.prix_vente, b.surface
FROM bien b
RIGHT JOIN vente v ON v.id_bien=b.id_bien
JOIN commune c ON c.id_com_insee=b.id_com_insee;
```

```
CREATE TEMP TABLE tmp_11b(cod_dep VARCHAR, nom_com VARCHAR, prix_metre FLOAT);
```

```
INSERT INTO tmp_11b(cod_dep, nom_com, prix_metre)
SELECT cod_dep, nom_com, prix_vente/surface AS prix_metre
FROM tmp_11
WHERE cod_dep = '06'
ORDER BY prix_metre DESC
LIMIT 3;
```

.....

.....

```
SELECT cod_dep, nom_com, round(prix_metre) FROM tmp_11b
```

	A-Z cod_dep	A-Z nom_com	123 prix_metre_car
1	06	Nice	70200.0
2	06	Roquebrune-Cap-Martin	48261.0
3	06	Cap-d'Ail	41562.0
4	13	Marseille 6e	27689.0
5	13	Marseille 14e	19231.0
6	13	Marseille 6e	12447.0
7	33	Lège-Cap-Ferret	20682.0
8	33	Talence	17208.0
9	33	Mérignac	16379.0
10	59	Lille	80833.0
11	59	Valenciennes	37667.0
12	59	La Madeleine	31182.0
13	69	Lyon 3e	34043.0
14	69	Collonges-au-Mont-d'Or	32035.0
15	69	Caluire-et-Cuire	29545.0

Requête 12

12. Les 20 communes avec le plus de transactions pour 1000 habitants pour les communes qui dépassent les 10 000 habitants.

```
SELECT c.nom_com, avg(c.pop_tot) AS population,  
ROUND(AVG(v.prix_vente)) AS Moyenne_du_prix,  
COUNT(id_vente)*1000/avg(c.pop_tot) AS nbr_vente_par_1000hab
```

```
FROM bien b  
RIGHT JOIN vente v ON v.id_bien=b.id_bien  
JOIN commune c ON c.id_com_insee=b.id_com_insee
```

```
WHERE c.pop_tot>=10000
```

```
GROUP BY c.nom_com  
ORDER BY nbr_vente_par_1000hab DESC  
LIMIT 20;
```

AZ nom_com	123 population	123 moyenne_du_prix	123 nbr_vente_par_1000hab
Paris 2e	21735	524494	5.7971014492753623
Paris 1er	16055	1024978	4.796013702896294
Paris 3e	34306	658346	4.6639071882469539
Arcachon	11898	307436	4.6226256513699781
La Baule-Escoublac	16797	264745	4.5841519318925999
Paris 4e	29390	650909	4.0489962572303505
Roquebrune-Cap-Martin	13041	274173	3.9874242772793497
Paris 8e	36250	1024383	3.7793103448275862
Paris 9e	60563	588414	3.401416706570018
Paris 6e	41171	1014722	3.3032960093269534
Sanary-sur-Mer	17160	286095	3.1468531468531469
Chantilly	11178	238481	3.1311504741456432
Saint-Mandé	22576	494061	3.056343019135365
Paris 10e	86863	533755	3.0277563519565292
Pornichet	11440	207723	2.972027972027972
La Londe-les-Maures	10776	153112	2.969561989606533
Menton	30981	208036	2.9050062941803041
Saint-Hilaire-de-Riez	11501	85265	2.8693157116772455
Saint-Cyr-sur-Mer	11725	278336	2.814498933901919
Vincennes	50230	435809	2.7871789767071471

Conclusion

- D'après l'analyse des données réalisée dans le cadre du POC, la région la plus prometteuse identifiée est l'Île-de-France.
- **Validation du POC** : les résultats démontrent qu'il est possible d'exploiter efficacement les données pour obtenir des indicateurs pertinents sur le marché immobilier.





Merci !