

Anticipez les besoins en consommation de bâtiments

Hishem HYANI

January 2, 2026

Sommaire

Introduction

1. EDA
2. Feature Engineering
3. Modèles supervisés
4. API

Conclusion

Introduction

Introduction

Contexte et problématique

La ville de Seattle souhaite :

- Prédire la consommation totale d'énergie de bâtiments non destinés à l'habitation
- Devenir une ville neutre en émissions de carbone en 2050.

Introduction

Contexte et problématique

La ville de Seattle souhaite :

- Prédire la consommation totale d'énergie de bâtiments non destinés à l'habitation
- Devenir une ville neutre en émissions de carbone en 2050.

Solution proposé:

- Analyser et préparer les données disponibles
- Comparer plusieurs modèles ML supervisés sur ce jeu de données
- Optimiser les performances du modèle de prédiction sélectionner
- Déployer le modèle final via une API (BentoML et AWS)

1. Analyse exploratoire

1.1. Colonnes du dataset

Le dataset est composé de 3376 lignes et 46 colonnes.

OSEBuildingID	DataYear	Building Type
PrimaryPropertyType	PropertyName	Address
City	State	ZipCode
TaxParcelIdentificationNumber	CouncilDistrictCode	Neighborhood
Latitude	Longitude	YearBuilt
NumberOfBuildings	NumberOfFloors	PropertyGFATotal
PropertyGFAParking	PropertyGFABuilding(s)	ListOfAllPropertyUseTypes
LargestPropertyUseType	LargestPropertyUseTypeGFA	SecondLargestPropertyUseType
SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA
YearsENERGYSTARCertified	ENERGYSTARScore	SiteEUI(kBtu/sf)
SiteEUIWN(kBtu/sf)	SourceEUI(kBtu/sf)	SourceEUIWN(kBtu/sf)
SiteEnergyUse(kBtu)	SiteEnergyUseWN(kBtu)	SteamUse(kBtu)
Electricity(kWh)	Electricity(kBtu)	NaturalGas(therms)
NaturalGas(kBtu)	DefaultData	Comments
ComplianceStatus	Outlier	TotalGHGEmissions
GHGEmissionsIntensity		

1.1. Colonnes du dataset

OSEBuildingID	DataYear	BuildingType
PrimaryPropertyType	PropertyName	Address
City	State	ZipCode
TaxParcelIdentificationNumber	CouncilDistrictCode	Neighborhood
Latitude	Longitude	YearBuilt
NumberOfBuildings	NumberOfFloors	PropertyGFATotal
PropertyGFAParking	PropertyGFABuilding(s)	ListOfAllPropertyUseTypes
LargestPropertyUseType	LargestPropertyUseTypeGFA	SecondLargestPropertyUseType
SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA
YearsENERGYSTARCertified	ENERGYSTARScore	SiteEUI(kBtu/sf)
SiteEUIWN(kBtu/sf)	SourceEUI(kBtu/sf)	SourceEUIWN(kBtu/sf)
SiteEnergyUse(kBtu)	SiteEnergyUseWN(kBtu)	SteamUse(kBtu)
Electricity(kWh)	Electricity(kBtu)	NaturalGas(therms)
NaturalGas(kBtu)	DefaultData	Comments
ComplianceStatus	Outlier	TotalGHGEmissions
GHGEmissionsIntensity		

Valeurs manquantes ou Colonnes non pertinentes

1.1. Colonnes du dataset

OSEBuildingID	DataYear	BuildingType
PrimaryPropertyType	PropertyName	Address
City	State	ZipCode
TaxParcelIdentificationNumber	CouncilDistrictCode	Neighborhood
Latitude	Longitude	YearBuilt
NumberOfBuildings	NumberOfFloors	PropertyGFATotal
PropertyGFAParking	PropertyGFABuilding(s)	ListOfAllPropertyUseTypes
LargestPropertyUseType	LargestPropertyUseTypeGFA	SecondLargestPropertyUseType
SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA
YearsENERGYSTARCertified	ENERGYSTARScore	SiteEUI(kBtu/sf)
SiteEUIWN(kBtu/sf)	SourceEUI(kBtu/sf)	SourceEUIWN(kBtu/sf)
SiteEnergyUse(kBtu)	SiteEnergyUseWN(kBtu)	SteamUse(kBtu)
Electricity(kWh)	Electricity(kBtu)	NaturalGas(therms)
NaturalGas(kBtu)	DefaultData	Comments
ComplianceStatus	Outlier	TotalGHGEmissions
GHGEmissionsIntensity		

Valeurs manquantes ou Colonnes non pertinentes

Valeur unique

1.2. Target

Le df est désormais composé de 3376 lignes et $46 - 13 = 33$ colonnes.

BuildingType	PrimaryPropertyType	PropertyName
ZipCode	CouncilDistrictCode	Neighborhood
Latitude	Longitude	YearBuilt
NumberOfBuildings	NumberOfFloors	PropertyGFATotal
PropertyGFAParking	PropertyGFABuilding(s)	ListOfAllPropertyUseTypes
LargestPropertyUseType	LargestPropertyUseTypeGFA	SecondLargestPropertyUseType
SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA
SiteEUI(kBtu/sf)	SiteEUIWN(kBtu/sf)	SourceEUI(kBtu/sf)
SourceEUIWN(kBtu/sf)	SiteEnergyUse(kBtu)	SiteEnergyUseWN(kBtu)
SteamUse(kBtu)	Electricity(kWh)	Electricity(kBtu)
NaturalGas(therms)	NaturalGas(kBtu)	DefaultData
ComplianceStatus	Outlier	

Consommation énergétique


1.2. Target

Le df est désormais composé de 3376 lignes et $46 - 13 = 33$ colonnes.

BuildingType	PrimaryPropertyType	PropertyName
ZipCode	CouncilDistrictCode	Neighborhood
Latitude	Longitude	YearBuilt
NumberOfBuildings	NumberOfFloors	PropertyGFATotal
PropertyGFAParking	PropertyGFABuilding(s)	ListOfAllPropertyUseTypes
LargestPropertyUseType	LargestPropertyUseTypeGFA	SecondLargestPropertyUseType
SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA
SiteEUI(kBtu/sf)	SiteEUIWN(kBtu/sf)	SourceEUI(kBtu/sf)
SourceEUIWN(kBtu/sf)	SiteEnergyUse(kBtu)	SiteEnergyUseWN(kBtu)
SteamUse(kBtu)	Electricity(kWh)	Electricity(kBtu)
NaturalGas(therms)	NaturalGas(kBtu)	DefaultData
ComplianceStatus	Outlier	

Consommation énergétique

1.2. Target



1.3. Localisation

Le df est désormais composé de 3376 lignes et $33-8 = 25$ colonnes.

BuildingType	PrimaryPropertyType	ZipCode
CouncilDistrictCode	Neighborhood	Latitude
Longitude	YearBuilt	NumberofBuildings
NumberofFloors	PropertyGFATotal	PropertyGFAParking
PropertyGFABuilding(s)	LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType
ThirdLargestPropertyUseTypeGFA	DefaultData	ComplianceStatus
Outlier		
Electricity(kBtu)	NaturalGas(kBtu)	
SiteEUIWN(kBtu/sf)		

Target

1.3. Localisation

Comment localiser les biens?

BuildingType	PrimaryPropertyType	ZipCode
CouncilDistrictCode	Neighborhood	Latitude
Longitude	YearBuilt	NumberofBuildings
NumberofFloors	PropertyGFATotal	PropertyGFAParking
PropertyGFABuilding(s)	LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType
ThirdLargestPropertyUseTypeGFA	DefaultData	ComplianceStatus
Outlier		
Electricity(kBtu)	NaturalGas(kBtu)	
SiteEUIWN(kBtu/sf)		

Target

Localisation

1.3. Localisation

Comment localiser les biens?

BuildingType	PrimaryPropertyType	ZipCode
CouncilDistrictCode	Neighborhood	Latitude
Longitude	YearBuilt	NumberOfBuildings
NumberOfFloors	PropertyGFATotal	PropertyGFAParking
PropertyGFABuilding(s)	LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType
ThirdLargestPropertyUseTypeGFA	DefaultData	ComplianceStatus
Outlier		
Electricity(kBtu)	NaturalGas(kBtu)	
SiteEUIWN(kBtu/sf)		

Target

Localisation

Variable	Cardinalité
ZipCode	55
CouncilDistrictCode	7
Neighborhood	13
Latitude	2876
Longitude	2656

1.3. Localisation

Comment localiser les biens?

BuildingType	PrimaryPropertyType	ZipCode
CouncilDistrictCode	Neighborhood	Latitude
Longitude	YearBuilt	NumberOfBuildings
NumberOfFloors	PropertyGFATotal	PropertyGFAParking
PropertyGFABuilding(s)	LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseType
ThirdLargestPropertyUseTypeGFA	DefaultData	ComplianceStatus
Outlier		
Electricity(kBtu)	NaturalGas(kBtu)	
SiteEUIWN(kBtu/sf)		


Target

Localisation

Variable	Cardinalité
ZipCode	55
CouncilDistrictCode	7
Neighborhood	13
Latitude	2876
Longitude	2656

1.3. Localisation

Un tableau croisé est combiné à une heatmap afin de représenter graphiquement la correspondance entre ces deux variables.



1.4. Type de Bien

Le df est désormais composé de 3376 lignes et $25-4 = 21$ colonnes.

BuildingType	PrimaryPropertyType	NumberofBuildings
NumberofFloors	PropertyGFATotal	PropertyGFAParking
PropertyGFABuilding(s)	LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA	
ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA	
DefaultData	ComplianceStatus	Outlier
YearBuilt	Neighborhood	
Electricity(kBtu)	NaturalGas(kBtu)	
SiteEUIWN(kBtu/sf)		

Target

Features

1.4. Type de Bien

Quelles colonnes utiliser pour retirer des biens non pertinents?

BuildingType	PrimaryPropertyType	NumberOfBuildings
NumberOfFloors	PropertyGFATotal	PropertyGFAParking
PropertyGFABuilding(s)	LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA	
ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA	
DefaultData	ComplianceStatus	Outlier
YearBuilt	Neighborhood	
Electricity(kBtu)	NaturalGas(kBtu)	
SiteEUIWN(kBtu/sf)		



Target



Features



Utilisées pour le nettoyage

1.4. Type de Bien

Quelles colonnes utiliser pour retirer des biens non pertinents?

BuildingType	PrimaryPropertyType	NumberOfBuildings
NumberOfFloors	PropertyGFATotal	PropertyGFAParking
PropertyGFABuilding(s)	LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA	
ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA	
DefaultData	ComplianceStatus	Outlier
YearBuilt	Neighborhood	
Electricity(kBtu)	NaturalGas(kBtu)	
SiteEUIWN(kBtu/sf)		



Target



Features



Utilisées pour le nettoyage

On a retirer :

- Les biens résidentiels
- Les outliers et valeurs manquantes ou erronées
- Les parking

1.4. Type de bien

Le df est désormais composé de 1525 lignes et $21-7 = 14$ colonnes.

LargestPropertyUseType	LargestPropertyUseTypeGFA
SecondLargestPropertyUseType	SecondLargestPropertyUseTypeGFA
ThirdLargestPropertyUseType	ThirdLargestPropertyUseTypeGFA
	PropertyGFABuilding(s)
NumberofBuildings	NumberofFloors
YearBuilt	Neighborhood
Electricity(kBtu)	NaturalGas(kBtu)
SiteEUIWN(kBtu/sf)	



Target



Features

2. Feature Engineering

2.1. Type de bien multiple

Variables	Etat initial	Proportion
LargestPropertyUseType	Bureau	
LargestPropertyUseTypeGFA	x	$P_x = \frac{x}{S_{tot}}$
SecondLargestPropertyUseType	Commerce	
SecondLargestPropertyUseTypeGFA	y	$P_y = \frac{y}{S_{tot}}$
ThirdLargestPropertyUseType	Habitation	
ThirdLargestPropertyUseTypeGFA	z	$P_z = \frac{z}{S_{tot}}$
PropertyGFABuilding(s)	$S_{tot} = x + y + z$	$S_{tot} = x + y + z$
SiteEUIWN(kBtu/sf)	E_{tot}	E_{tot}

2.1. Type de bien multiple


Variables	Bien 1	Bien 2	Bien 3
LargestPropertyUseType	Bureau	Commerce	Habitation
LargestPropertyUseTypeGFA	$P_x \times S_{tot}$	$P_y \times S_{tot}$	$P_z \times S_{tot}$
SecondLargestPropertyUseType			
SecondLargestPropertyUseTypeGFA			
ThirdLargestPropertyUseType			
ThirdLargestPropertyUseTypeGFA			
PropertyGFABuilding(s)	x	y	z
SiteEUIWN(kBtu/sf)	$P_x \times E_{tot}$	$P_y \times E_{tot}$	$P_z \times E_{tot}$

2.1. Type de bien multiple


Variables	Bien 1	Bien 2	Bien 3
LargestPropertyUseType	Bureau	Commerce	Habitation
LargestPropertyUseTypeGFA	$P_x \times S_{tot}$	$P_y \times S_{tot}$	$P_z \times S_{tot}$
SecondLargestPropertyUseType			
SecondLargestPropertyUseTypeGFA			
ThirdLargestPropertyUseType			
ThirdLargestPropertyUseTypeGFA			
PropertyGFABuilding(s)	x	y	z
SiteEUIWN(kBtu/sf)	$P_x \times E_{tot}$	$P_y \times E_{tot}$	$P_z \times E_{tot}$

Le df est désormais composé de $1525 + 312 = 1837$ lignes et $14 - 5 = 9$ colonnes.

2.1. Type de bien multiple



2.1. Type de bien multiple



2.2.Encodage des variables

Nous avons ensuite transformer certaines variables brutes en variables exploitables par les modèles de Machine Learning.

- **Binarisation des usages énergétiques**
 - Électricité
 - Gaz naturel
- **Encodage One-Hot des variables catégorielles**
 - Neighborhood
 - Type de bâtiment

2.2.Encodage des variables

Nous avons ensuite transformer certaines variables brutes en variables exploitables par les modèles de Machine Learning.

- **Binarisation des usages énergétiques**
 - Électricité
 - Gaz naturel
- **Encodage One-Hot des variables catégorielles**
 - Neighborhood
 - Type de bâtiment

Le df final est composé de 1606 lignes et 29 colonnes

3. Modèles supervisés

3.1. Crossvalidation

Pour réaliser la comparaison nous avons utilisé la cross validation :

Val	Train	Train	Train	Train
Train	Val	Train	Train	Train
Train	Train	Val	Train	Train
Train	Train	Train	Val	Train
Train	Train	Train	Train	Val

3.2. Comparaison des performances

Modèle utilisé	CV: RMSE moyenne		RMSE Test
	Validation	Train	
Régression linéaire	23.46	22.87	24.06
Random Forest	20.58	7.57	21.90
SVR	26.27	25.82	23.31

3.2. Comparaison des performances

Modèle utilisé	CV: RMSE moyenne		RMSE Test
	Validation	Train	
Régression linéaire	23.46	22.87	24.06
Random Forest	20.58	7.57	21.90
SVR	26.27	25.82	23.31

3.2. Comparaison des performances

Modèle utilisé	CV: RMSE moyenne		RMSE Test
	Validation	Train	
Régression linéaire	23.46	22.87	24.06
Random Forest	20.58	7.57	21.90
SVR	26.27	25.82	23.31

Analyse : Meilleures performances pour Random Forest mais avec un sur-apprentissage.

3.3. Optimisation



3.3. Optimisation



Résultats :

Phase	Train	Test
Avant optimisation	7.57	21.90
Après optimisation	15.61	21.67

3.3. Optimisation



Résultats :


Phase	Train	Test
Avant optimisation	7.57	21.90
Après optimisation	15.61	21.67

Analyse :

- L'optimisation permet de réduire le sur-apprentissage.
- Légère amélioration sur le Test.

4. API

4. API



Le modèle optimisé est emballé avec BentoML, conteneurisé via Docker, puis déployé sur AWS.

Conclusion

Conclusion

Étapes réalisées

- EDA / Nettoyage
- Feature Engineering
- Modélisation (RL / SVR / RF)
- Optimisation GridSearchCV
- Déploiement d'une API BentoML / Docker / AWS

Conclusion

Étapes réalisées

- EDA / Nettoyage
- Feature Engineering
- Modélisation (RL / SVR / RF)
- Optimisation GridSearchCV
- Déploiement d'une API BentoML / Docker / AWS

La mairie peut désormais utilisé la première version de l'API pour prédire la consommation énergétique.