

Forecast 2.0

Intégration de nouvelles sources de données dans la BDD

Hishem HYANI – Data Engineer

GreenAndCoop

March 19, 2026

Sommaire

Introduction

1. Schéma de la base de données
2. Logigramme ETL
3. L'architecture de la base de données
4. Airbyte
5. AWS

Conclusion

Introduction

Contexte: Projet Forecast 2.0

- Nouvelles données météorologiques pour la prévision
- DSI impose de travailler avec AWS et Docker

Solution : Pipeline ETL automatisé sur AWS

- Ingestion des données via Airbyte vers Amazon S3.
- Traitement des données avec Python conteneurisé sur EC2.
- Stockage final dans DocumentDB.

Introduction

Contexte: Projet Forecast 2.0

- Nouvelles données météorologiques pour la prévision
- DSI impose de travailler avec AWS et Docker

Solution : Pipeline ETL automatisé sur AWS

- Ingestion des données via Airbyte vers Amazon S3.
- Traitement des données avec Python conteneurisé sur EC2.
- Stockage final dans DocumentDB.

1.1. Sources de données

Point de comparaison	InfoClimat	Weather Underground
Unités utilisées	°C-mm-km/h	°F-in-mph
Champs numériques	Sans unité	Unité intégrée
Direction du vent	Angle (degrés)	En lettre
Datetime utc	Oui	Non

Constats :

- Unités de mesure différentes
- Formats de données hétérogènes
- Schémas de données non uniformes

Solution :

Définir un schéma de données commun et flexible

1.1. Sources de données

Point de comparaison	InfoClimat	Weather Underground
Unités utilisées	°C-mm-km/h	°F-in-mph
Champs numériques	Sans unité	Unité intégrée
Direction du vent	Angle (degrés)	En lettre
Datetime utc	Oui	Non

Constats :

- Unités de mesure différentes
- Formats de données hétérogènes
- Schémas de données non uniformes

Solution :

Définir un schéma de données commun et flexible

1.1. Sources de données

Point de comparaison	InfoClimat	Weather Underground
Unités utilisées	°C-mm-km/h	°F-in-mph
Champs numériques	Sans unité	Unité intégrée
Direction du vent	Angle (degrés)	En lettre
Datetime utc	Oui	Non

Constats :

- Unités de mesure différentes
- Formats de données hétérogènes
- Schémas de données non uniformes

Solution :

Définir un schéma de données commun et flexible

1.2. Schéma de la BDD

- Index unique :

- ("id_station","dh_utc")

1.2. Schéma de la BDD

- **Index unique :**

- ("id_station","dh_utc")

- **Type :**

- id_station, city : string
- dh_utc : ISODate
- Autres champs : Float64

1.2. Schéma de la BDD

- **Index unique :**
 - ("id_station","dh_utc")
- **Type :**
 - id_station, city : string
 - dh_utc : ISODate
 - Autres champs : Float64
- **Choix des Unités**
 - °C, hPa, km/h,

1.2. Schéma de la BDD

- Index unique :

- ("id_station", "dh_utc")

- Type :

- id_station, city : string
- dh_utc : ISODate
- Autres champs : Float64


- Choix des Unités

- °C, hPa, km/h,


Exemple de document

```
{
  _id: ObjectId('69754297801b196d7ebd74c7'),
  id_station: '07015',
  dh_utc: ISODate('2024-10-05T00:00:00.000Z'),
  temperature: 7.6,
  pression: 1020.7,
  humidite: 89,
  point_de_rosee: 5.9,
  visibilite: 6000,
  vent_moyen: 3.6,
  vent_rafales: 7.2,
  vent_direction: 90,
  pluie_3h: 0,
  taux_precipitation: 0,
  neige_au_sol: null,
  nebulosite: null,
  temps_omm: null,
  pluie_24h: null,
  indice_UV: null,
  rayonnement_solaire: null,
  city: 'Lille-Lesquin',
  latitude: 50.575,
  longitude: 3.092,
  elevation: 47
}
```

2. Logigramme ETL




2. Logigramme ETL



Test de cohérence :

- $\text{vent_direction} \in [0; 360]$
- $\text{humidite} \in [0; 100]$

3. L'architecture de la base de données



4. Airbyte

Sources / File (CSV, JSON, Excel, Feather, Parquet)

 **File (CSV, JSON, Excel, Feather, Parquet)** File (CSV, JSON, Excel, Feather, Parquet) v0.6.0 Fork

Settings Connections

Source Settings

Source name ⓘ

Dataset Name ⓘ

File Format ⓘ

Storage Provider ⓘ ⓘ
Optional fields

URL ⓘ

Optional fields

Test the source Retest saved source

Delete this source Copy JSON Cancel Test and save

4. Airbyte

Sources / File (CSV, JSON, Excel, Feather, Parquet)



File (CSV, JSON, Excel, Feather, Parquet)

File (CSV, JSON, Excel, Feather, Parquet) v0.6.0

Fork

Settings Connections

Source Settings

Source name ⓘ

File (CSV, JSON, Excel, Feather, Parquet)

Dataset Name ⓘ

Stations météorologiques du réseau InfoClimat

File Format ⓘ

json

Storage Provider ⓘ

HTTPS: Public Web

> Optional fields

URL ⓘ

https://s3.eu-west-1.amazonaws.com/course.oc-static.com/projects/922_Data+Engineer/922_P8/Data_Source

> Optional fields

Test the source

Retest saved source

Delete this source

Copy JSON

Cancel

Test and save

Destinations / S3



S3

S3 v1.9.5

Settings Connections

Destination Settings

Destination name ⓘ

S3

Access Key ID ⓘ Optional

Edit

Secret Access Key ⓘ Optional

Edit

S3 Bucket Name ⓘ

projet08

S3 Bucket Path ⓘ

raw/airbyte

S3 Bucket Region ⓘ

eu-west-3

Output Format ⓘ

JSON Lines: Newline-delimited JSON

Compression ⓘ

No Compression

> Optional fields

> Optional fields

5. AWS

EC2:

EC2

Tableau de bord
AWS Global View
Événements

▼ **Instances**
Instances
Types d'instances
Modèles de lancement
Demandes Spot
Samlane Dlane

Instances (1/1) Informations

Rechercher Instance par attribut ou identification (case-sensitive)

Tous les états

Se connecter État de l'instance Actions Lancer des instances



☒	Name	ID d'instance	État de l'instance	Type d'instance	Contrôle des stat	Statut d'alarm	Zone de dispon	DNS IPv4 public
☒	docudb-python	i-010275c7400d87bc9	En cours d'exécution	t3.micro	3/3 vérifications	Afficher les alarm	eu-west-3c	ec2-15-188-54-22.eu-w...

Documentdb :

☐	☒ Identifiant du cluster	Statut	Rôle	Version du moteur	Région et zone d...	État de l'insta...	CPU
☐	☒ docdb-projet08	Available	Cluster régional	8.0.0	eu-west-3	-	-
☐	☐ docdb-projet08	Available	Instance principale	8.0.0	eu-west-3c	En bon état	23.23%
☐	☐ docdb-projet082	Available	Instance de réplica	8.0.0	eu-west-3a	En bon état	21.77%
☐	☐ docdb-projet083	Available	Instance de réplica	8.0.0	eu-west-3b	En bon état	23.61%

5. AWS

Cloudwatch :



Conclusion

Réalisé : Pipeline ETL automatisé sur AWS

- Ingestion des données via Airbyte vers Amazon S3.
- Traitement des données avec Python conteneurisé sur EC2.
- Stockage final dans DocumentDB avec replicaset.
- Monitoring sur CloudWatch.

Conclusion

Réalisé : Pipeline ETL automatisé sur AWS

- Ingestion des données via Airbyte vers Amazon S3.
- Traitement des données avec Python conteneurisé sur EC2.
- Stockage final dans DocumentDB avec replicaset.
- Monitoring sur CloudWatch.

Perspective futur

- Ingestion Airbyte à partir d'une source API
- Ajouter le sharding à Documentdb
- Gestion des valeurs manquantes ou erronés
- Optimiser les scripts l'ETL
- Connecter la base de donné à SageMaker