

Mise en place d'un pipeline d'orchestration des flux

Hishem HYANI – Data Engineer

BottleNeck

March 9, 2026

Sommaire

Introduction

1. Diagramme de flux des tâches
2. Kestra
3. Tests

Conclusion

Introduction

Contexte :

Stéphane a réalisé manuellement une première chaîne de traitement afin d'analyser les données issues des systèmes ERP et CMS.

Problématique :

L'objectif est désormais d'automatiser et de fiabiliser cette chaîne de traitement et d'analyse de données.

Solution :

Pour répondre à ce besoin, on :

- Utilise Kestra plateforme d'orchestration
- Fiabilise les traitements avec des tests
- Automatise cet enchaînement avec un trigger

Introduction

Contexte :

Stéphane a réalisé manuellement une première chaîne de traitement afin d'analyser les données issues des systèmes ERP et CMS.

Problématique :

L'objectif est désormais d'automatiser et de fiabiliser cette chaîne de traitement et d'analyse de données.

Solution :

Pour répondre à ce besoin, on :

- Utilise Kestra plateforme d'orchestration
- Fiabilise les traitements avec des tests
- Automatise cet enchaînement avec un trigger

Introduction

Contexte :

Stéphane a réalisé manuellement une première chaîne de traitement afin d'analyser les données issues des systèmes ERP et CMS.

Problématique :


L'objectif est désormais d'automatiser et de fiabiliser cette chaîne de traitement et d'analyse de données.

Solution :

Pour répondre à ce besoin, on :

- Utilise Kestra plateforme d'orchestration
- Fiabilise les traitements avec des tests
- Automatise cet enchaînement avec un trigger

1. Diagramme de flux des tâches



2. Kestra

```
hisdat@hisdat-A8-MAX: ~/Data_2025/Projet_10/V0.5
hisdat@hisdat-A8-MAX:~/Data_2025/Projet_10/V0.5$ docker run -d --pull=always -it -p 8080:8080 --user=root --name kestra2 --restart=always -v ./kestra_data:/app/storage -v /var/run/docker.sock:/var/run/docker.sock -v /tmp:/tmp -e 'KESTRA_CONFIGURATION=kestra: { local-files: { allowed-paths: [ "/app/storage" ] } }' kestra/kestra:latest server local
```

Remarques :

- Docker et persistance des données





- Docker et persistance des données
- Accès à la plateforme via localhost:8080

3.1. Test sur le nettoyage

```
=====
=== Fichier ERP ===
Date: 2026-03-05 19:01:43|
Nombre de lignes lues : 825
Colonnes presentes : product_id, price
Aucun doublon sur product_id

VERIFICATION VALEURS MANQUANTES
-> product_id manquants : 0
-> price manquants : 0
-> Total manquants : 0
OK - Aucune valeur manquante sur product_id et price
```

```
=====
=== Fichier CMS ===
Date: 2026-03-05 19:01:43
Nombre de lignes lues : 714
Colonnes presentes : id_web, total_sales, post_title
Aucun doublon sur id_web

VERIFICATION VALEURS MANQUANTES
-> id_web manquants : 0
-> total_sales manquants : 0
-> Total manquants : 0
OK - Aucune valeur manquante sur id_web et total_sales
```

Remarques :

- Cohérence sur le nombre de lignes.
- Pas de doublons sur les clés primaires
- Aucune valeur manquantes

3.2. Test sur la jointure

```

1 -----
2 === Fichier jointure ===
3 Date: 2026-03-06 15:02:56
4 Nombre de lignes lues : 714
5 Colonnes presentes : product_id, id_web, price, total_sales, post_title
6 Aucun doublon sur les id
7
8 VERIFICATION VALEURS MANQUANTES
9 -> id_web manquants      : 0
10 -> product_id manquants : 0
11 -> Total manquants      : 0
12 OK - Aucune valeur manquante sur id_web et product_id
13
14 VOLUMETRIE DES DONNEES
15 Nombre de lignes ERP avant jointure : 825
16 Nombre de lignes CMS avant jointure : 714
17 Nombre de lignes après jointure     : 714
18 OK - La volumétrie des données après les jointures est cohérente
19
20 -----

```

Remarques :

- Cohérence sur le nombre de lignes.
- Pas de doublons sur les clés primaires
- Aucune valeur manquantes

3.3. Résultats de l'analyse

```
-----  
=== Résultats ===  
Date: 2026-03-06 15:03:15  
CA : 70568.60 €  
-> Nombre de bouteilles premiums : 30  
-> Nombre de bouteilles ordinaires : 684  
-> Total (ordinaires + premiums) : 714
```

Remarques :

- Chiffre d'affaire cohérent
- Cohérence de la volumétrie des vins millésimes et ordinaires

Conclusion

Objectifs atteints

- Automatisation d'une chaîne de traitement et d'analyse de données.
- Validation du pipeline
- Extraction fiable (CA, volumétrie, rapport détaillé)

Perspectives d'amélioration

- Optimisation des performances
- Notifications automatiques des résultats

Conclusion

Objectifs atteints

- Automatisation d'une chaîne de traitement et d'analyse de données.
- Validation du pipeline
- Extraction fiable (CA, volumétrie, rapport détaillé)

Perspectives d'amélioration

- Optimisation des performances
- Notifications automatiques des résultats